

Friday 앱 설계서

Offline - first Personal AI Assistant for Android / Windows Expansion

대상: Galaxy S25 Ultra 기반 Android MVP, 이후 Windows 확장

메인 모델: Gemma 4 E4B - it / 데스크톱 확장: Gemma 4 26B - A4B

목차

1. 서비스 개요
2. 핵심 기능 요약
3. 서비스 플로우
4. 화면 설계서(UI/UX)
5. 기능 명세서
6. AI 기능 설계
7. 시스템 아키텍처
8. 데이터 및 상태 관리
9. 보안 및 예외 처리
10. 개발 우선순위
11. 기술 스택
12. 최종 정리

1. 서비스 개요

- 목적: Android 스마트폰에서 로컬 LLM을 사용하여 오프라인 우선 개인 AI 비서를 제공한다. 핵심 기능은 텍스트 채팅, push-to-talk 음성 입력, 이미지 입력, 캘린더 조회 및 일정 초안 생성, 메모리 관리, 질문 단위 웹 검색이다.
- 핵심 사용자: Galaxy S25 Ultra 단일 사용자. 개인정보를 외부 API로 전송하지 않고 개인 비서를 로컬에서 사용하려는 고급 사용자.
- 문제 정의: 일반 클라우드 기반 AI 비서는 개인 일정, 메모, 문서, 음성 입력을 다루는 과정에서 개인정보 외부 전송이 발생한다. 또한 검색/실행/기억이 분리되어 있어 개인 비서 경험이 약하다.
- 차별점: 기본 오프라인 처리, 질문 단위 검색 ON, 로컬 메모리 5계층(Profile/Conversation/Task/Knowledge/Audit), 승인 기반 쓰기 작업, 모델 교체 가능한 구조, Android 우선 + Windows 확장 가능 아키텍처.

2. 핵심 기능 요약

기능명	설명	우선순위	AI 활용 여부
로컬 채팅	Gemma 4 E4B - it 기반 텍스트 질의응답	MVP	예
음성 입력	push-to-talk STT 후 채팅으로 전달	MVP	부분 사용
이미지 입력	스크린샷/문서 이미지 기반 질의응답	MVP	예
캘린더 조회	오늘/주간 일정 조회 및 요약	MVP	예
일정 초안 생성	자연어 요청을 캘린더 초안으로 변환, 승인 후 저장	MVP	예
메모리 관리	대화/작업/지식/로그 저장 및 조회	MVP	예
질문 단위 검색	현재 질문에 한해 웹 검색 허용	v1	예
export/import	메모리 및 설정 내보내기/가져오기	v1	아니오
공유 인텐트	외부 앱 텍스트/이미지 공유 수신	v1	부분 사용

3. 서비스 플로우

- 전체 사용자 흐름: 앱 실행 → 모델/메모리 로드 → 채팅/음성/이미지 입력 → AssistantOrchestrator가 의도 분석 → 로컬 메모리 검색 → ModelRunner 실행 → 응답 또는 액션 초안 생성 → 쓰기 작업은 승인 요청 → 승인 후 Tool 실행 → 결과 저장 및 Audit 기록.
- 로그인: MVP에서는 다중 사용자 로그인 미구현. 앱 최초 실행 시 로컬 프로필 생성. 향후 Windows 연동 시 사용자 프로필 파일 import로 동일 사용자 식별.
- 권한 없음 분기: 캘린더 권한 미허용 시 권한 요청 다이얼로그 노출 → 거부 시 읽기/쓰기 기능 비활성 + 설정 이동 버튼 제공.
- 네트워크 오류 분기: 검색 ON 상태에서만 네트워크 사용. 검색 요청 실패 시 로컬 응답만 유지하고 '웹 검색 보강 실패' 메시지 표시.
- 중복 요청 분기: 동일 입력이 연속 전송되면 ViewModel에서 in-flight 상태를 확인하여 중복 전송 차단.
- 모델 로드 실패 분기: 설정 화면에서 모델 경로 확인 유도, 오류 코드와 함께 재시도 버튼 제공.

4. 화면 설계서(UI/UX)

- 공통 디자인: 메인 컬러 #5bc2e7, 배경 #f7fbfd, Surface #ffffff, 주요 CTA는 하늘색 채움 버튼, 보조 액션은 테두리 버튼. 하단 탭 4개(채팅/일정/메모리/설정), 우하단 FAB는 음성 입력.
- 채팅 화면 목적: 비서와의 주 상호작용. UI 요소: 상태 카드(오프라인/모델/질문 검색), 메시지 리스트, 첨부 프리뷰, 입력창, 이미지 버튼, 질문 단위 검색 토글, 전송 버튼, 음성 FAB. 상태: idle(초기), loading(응답 생성 중), success(응답 표시), empty(대화 없음), error(모델 실패). 예외 처리: 모델 실패 시 재시도 버튼, 이미지 첨부 실패 시 첨부 제거 및 오류 토스트.
- 음성 입력 오버레이 목적: push-to-talk 처리. UI 요소: 마이크 원형, 파형, 인식 텍스트, 취소/보내기 버튼. 상태: idle, listening, transcribing, success, error. 예외 처리: 마이크 권한 거부 시 권한 요청 또는 텍스트 입력 전환

안내.

- 일정 화면 목적: 일정 조회 및 AI 일정 초안 검토. UI 요소: 상단 요약 카드, 세그먼트 탭(오늘/이번 주/초안), 일정 리스트, 초안 카드. 상태: idle, loading, success, empty, error. 예외 처리: 캘린더 권한 거부 시 안내 카드, 일정 없음 시 empty state 표시.
- 메모리 화면 목적: 5계층 메모리 조회 및 export/import. UI 요소: 메모리 필터 칩, 검색 바, 리스트, export/import 버튼. 상태: idle, loading, success, empty, error. 예외 처리: import 파일 형식 오류, export 저장소 권한 없음.
- 설정 화면 목적: 모델 정보, 응답 스타일, 보안/검색 정책, 로그 확인. UI 요소: 모델 카드, 스타일 섹션, 정책 섹션, 로그 보기, 저장공간 정보. 예외 처리: 모델 파일 미존재, 로그 파일 손상.
- 전환 애니메이션: 탭 전환 crossfade + horizontal slide 220~280ms, 바텀시트 250~300ms, 카드 등장 fade + 8~12dp upward motion 160~220ms.

5. 기능 명세서

- [로컬 채팅] 목적: 텍스트 기반 AI 비서 응답 제공. 시나리오: 사용자가 메시지 입력 → 최근 대화 + 관련 메모리 결합 → Gemma 응답 생성 → Conversation/Audit 저장. Input: text, selected image(optional), search flag(boolean). Output: assistant response text, optional action card. 데이터 흐름: UI → ChatViewModel → SendChatMessageUseCase → AssistantOrchestrator → ContextBuilder → ModelRunner → repositories 저장 → UI. API 구조: 로컬 함수 호출만 사용, 외부 API 없음. DB: conversations, audit_events. 예외: 빈 입력 validation error, 모델 timeout, 중복 전송 차단.
- [음성 입력] 목적: 음성을 텍스트로 변환 후 동일 채팅 흐름으로 전달. 시나리오: FAB 탭 → STT 시작 → 텍스트 확인 → 전송. Input: microphone stream. Output: transcribed text. 데이터 흐름: VoiceInputController → AndroidSpeechToTextTool → ChatViewModel. API: Android SpeechRecognizer. 예외: 권한 없음, STT 실패, 무음 입력.
- [이미지 입력] 목적: 스크린샷/문서 이미지 기반 질의응답. 시나리오: 첨부 버튼 → 갤러리/스크린샷 선택 → 프리뷰 표시 → 질문 전송 → 멀티모달 실행. Input: URI + prompt text. Output: 요약/설명/할 일 추출. 데이터 흐름: UI → UriResolver → ImageInputAdapter → ModelRunner. API: Android storage/file picker. DB: optional knowledge_notes 저장. 예외: 파일 읽기 실패, 지원하지 않는 형식, 너무 큰 이미지.
- [캘린더 조회] 목적: 로컬 캘린더 일정 읽기 및 요약. 시나리오: 일정 탭 진입 → CalendarTool 조회 → AI 요약. Input: date range. Output: list of events + summary text. 데이터 흐름: CalendarViewModel → GetTodayScheduleUseCase → AndroidCalendarTool → optional ModelRunner summary. API: Android Calendar Provider. 예외: 권한 없음, 빈 일정, provider read failure.
- [일정 초안 생성/승인] 목적: 자연어를 일정 초안 구조로 변환하고 승인 후 저장. 시나리오: 사용자가 '내일 3시 병원 일정 잡아줘' 입력 → CreateCalendarDraftUseCase가 title/start/end/note 생성 → ApprovalSheet 표시 → 승인 시 CalendarTool.insert 실행. Input: natural language request. Output: CalendarDraft or validation error. DB: audit_events, tasks(optional). 예외: 시간 정보 누락, 중복 일정, 캘린더 쓰기 권한 없음, 사용자 승인 거부.
- [메모리 관리] 목적: 프로필, 대화, 작업, 지식, 감사 로그 저장/조회. 시나리오: 앱 사용 중 자동 저장, 메모리 탭에서 필터별 조회. DB 모델: profiles(id,user_name,preferred_response_style,...), conversations(id,session_id,role,content,input_type,created_at), tasks(id,title,status,priority,...), knowledge_notes(id,title,content,source_type,tags,...), audit_events(id,event_type,event_detail,approval_status,network_used,...). 예외: DB write failure, migration failure, corrupted row.
- [질문 단위 검색] 목적: 현재 질문에 한해서만 웹 검색 보강 허용. 시나리오: 사용자가 토글 ON → 전송 → SearchAgent 실행 → 실패 시 로컬 응답 유지. Input: prompt + search_flag=true. Output: local response + optional search augmentation card. API 구조: WebSearchGateway abstraction, 실제 구현은 향후 선택. 예외: timeout, no result, network unavailable, user did not enable flag.
- [export/import] 목적: 메모리 및 설정 내보내기/복원. 시나리오: 메모리 탭 → export 선택 → JSON + SQLite 묶음 생성 → import 시 manifest 검증 후 복원. Input: target file path or import file URI. Output: zip or restored DB/settings. 예외: 저장소 권한 없음, manifest mismatch, DB schema mismatch, insufficient space.

6. AI 기능 설계

- 사용 모델: Android MVP는 Gemma 4 E4B - it. 데스크톱 확장 시 Gemma 4 26B - A4B 사용. 클라우드 GPT/Claude는 MVP에서 미사용, 향후 선택 옵션.
- AI 역할: chatbot + planner + assistant agent. 로컬 답변 생성, 캘린더 초안 생성, 메모/문서 요약, 일정 요약, 질문 단위 검색 보강 응답.
- Prompt 흐름: PersonaProfile + 현재 요청 + 최근 대화 + 관련 메모리 검색 결과 + 정책 컨텍스트(검색 허용 여부/쓰기 승인 필요)를 PromptAssembler에서 조합. 구조화 출력이 필요한 경우 JSON 스키마 프롬프트 사용.
- RAG 여부: 제한적 로컬 RAG 사용. Vector DB는 MVP에서 미도입, 대신 KnowledgeRepository에서 최근/태그 기반 검색. v1 이후 벡터 인덱스 파일 도입 가능.
- Memory: Profile/Conversation/Task/Knowledge/Audit 5계층. Conversation은 최근 문맥, Task는 진행 중 업무, Knowledge는 저장 메모 및 요약본, Audit은 실행 기록.
- Agent 구조: AssistantOrchestrator → TaskRouter → CalendarAgent/MemoAgent/DocumentAgent/SearchAgent. Agent는 작업 분기와 구조화 결과 생성 담당. 실제 Android API 호출은 Tool 계층 수행.
- Tool Calling: Model이 직접 Android API를 호출하지 않고, JSON 구조화 결과를 생성한 후 UseCase/Agent가 Tool을 호출. 캘린더 쓰기와 검색은 PreExecutionGuard + ApprovalCoordinator를 반드시 거친다.
- 예상 latency: 텍스트 응답은 기기 성능 기준 수 초 이내 목표, 이미지 입력은 텍스트보다 더 길 수 있음. 비용: 기본 오프라인이므로 클라우드 비용 없음. 검색 기능만 네트워크 비용 발생 가능.

7. 시스템 아키텍처

- Presentation Layer: Compose UI, ViewModel, Navigation. feature/chat, feature/calendar, feature/memory, feature/settings, feature/approval.
- Assistant Core Layer: AssistantOrchestrator, TaskRouter, ContextBuilder, PromptAssembler, ResponseFormatter, ApprovalCoordinator.
- Domain Layer: models, repositories interfaces, use cases, policy interfaces, ModelRunner abstraction.
- Data Layer: Room DB, DataStore, file storage, repository implementations, export/import manager.
- Runtime Layer: GemmaModelRunner, GemmaRuntimeManager, multimodal adapters, runtime metrics collector.
- Platform Layer: AndroidCalendarTool, AndroidSpeechToTextTool, ShareIntentHandler, AndroidFileTool, WebSearchGateway.
- 흐름: UI 이벤트 → ViewModel → UseCase → AssistantOrchestrator → Memory load → ModelRunner or Tool path → 결과 검증 → Repository 저장 → UI state 업데이트.

8. 데이터 및 상태 관리

- 인증 방식: MVP는 단일 로컬 사용자 프로필 기반, JWT/OAuth 미사용. 다중 기기 연속성은 export/import로 해결. 향후 데스크톱 sync 시 사용자 프로필 파일 기반 식별.
- 캐싱 전략: 최근 대화와 최근 조회 일정은 메모리 캐시 + Room 저장. 검색 결과는 세션 캐시 미사용, 질문 단위 즉시 폐기.
- Pagination: MVP에서는 대화/메모리 목록에 간단한 페이지 단위 또는 최신순 lazy loading 사용. 무한 스크롤 필요 시 Room PagingSource 적용 가능.
- 상태 관리: 각 화면은 idle/loading/success/empty/error 5상태를 ViewModel에서 명시적으로 관리. in-flight 플래그로 중복 요청 차단.
- 실시간 처리 여부: 실시간 스트리밍 응답은 MVP에서 선택 사항. 기본은 비스트리밍 완결 응답. STT는 실시간 부분 텍스트 표시 허용.

9. 보안 및 예외 처리

- JWT 인증: MVP는 사용하지 않음. 단일 로컬 사용자이므로 앱 내부 프로필과 파일 권한으로 관리.
- 권한 처리: 캘린더 읽기/쓰기 권한, 마이크 권한, 저장소/파일 접근 권한을 기능 진입 시 요청. 거부 시 해당 기능 비활성 + 설정 이동 제공.
- Rate Limiting: 로컬 앱 내부에서 버튼 연타 방지, 동일 요청 중복 전송 차단, 음성 입력 동시 실행 금지.
- 개인정보 보호: 기본 오프라인 처리, 검색 ON인 질문만 외부 네트워크 사용. 검색 사용 여부는 Audit에 기록. 모델/대화/메모리는 로컬 저장.
- 로그 정책: audit_events 테이블에 모델 실행, 검색 사용, 승인/거부, 도구 호출, 오류 코드 기록. 민감 본문 전체 저장은 옵션으로 비활성화 가능.
- 예외 처리 상세: validation error(빈 입력/시간 누락), permission denied, provider failure, DB failure, model runtime error, timeout, no result, import schema mismatch.

10. 개발 우선순위

- MVP: 프로젝트 세팅, Gemma 로컬 연결, 텍스트 채팅, Conversation/Profile memory, 음성 입력, 이미지 입력, 캘린더 조회, 일정 초안 + 승인, 기본 설정 화면.
- v1: Task/Knowledge/Audit memory 확장, export/import, 질문 단위 검색, 공유 인텐트, 성능 로그.
- v2: Windows 앱 지원, Gemma 4 26B - A4B 연동, 로컬 네트워크 동기화, 고도화된 task memory, 벡터 인덱스 기반 로컬 RAG.

11. 기술 스택

- Frontend(Android): Kotlin, Jetpack Compose, Navigation, Hilt 또는 Koin, ViewModel, StateFlow.
- Backend: MVP 없음. 모든 주요 기능은 로컬 실행. 검색 기능은 OptionalSearchGateway abstraction만 구현.
- AI: Gemma 4 E4B - it 로컬 런타임, 멀티모달 입력 어댑터, 구조화 출력 파서.
- DB: Room(SQLite), DataStore(JSON/Preferences 성격 설정), 파일 저장소(export/import, 첨부, 모델 경로).
- Windows 확장 후보: Kotlin Multiplatform 공용 도메인 또는 별도 데스크톱 코어 재사용 + Gemma 4 26B - A4B 로컬 런타임.

12. 최종 정리

- 핵심 리스크: 모바일 발열 및 응답 시간, 이미지 입력 품질 편차, Android 권한/Provider 예외, 메모리 스키마 진화에 따른 migration 복잡성.
- 기술 난이도: 중상. 단일 기능은 구현 가능하나 로컬 모델 실행, 승인 흐름, 메모리 5계층, 멀티모달 입력, 오프라인 정책을 함께 맞추는 작업이 난이도를 높인다.
- 확장 가능성: 모델 교체, Windows 확장, 선택적 검색/클라우드 fallback, 로컬 RAG, 추가 Android 도구 연동 모두 가능하도록 구조를 설계했다.
- 운영 고려사항: 모델 파일 관리, DB migration 전략, export/import 호환 버전 관리, 로그 보존 정책, 성능/발열 프로파일링, 질문 단위 검색 정책 유지가 중요하다.