

오프라인 우선 개인 AI 비서 앱

MVP PRD

프로젝트 코드명: Local Friday (가칭)

가독성을 우선한 심플 문서 버전

대상 환경: Galaxy S25 Ultra / Android / Gemma 4 E4B - it

확장 고려: Windows / Gemma 4 26B - A4B

목차

1. 문서 목적
2. 프로젝트 목표
3. 제품 비전
4. 타겟 사용자
5. 핵심 사용 시나리오
6. 제품 범위
7. 기능 요구사항
8. 비기능 요구사항
9. 시스템 정책
10. 메모리 설계 요구사항
11. 모델 및 런타임 요구사항
12. UI/UX 요구사항
13. 기술적 아키텍처 요구사항
14. 릴리즈 단계 제안
15. 수용 기준
16. 리스크 및 대응
17. 향후 확장 방향
18. 최종 결정 요약

1. 문서 목적

- 본 문서는 삼성 Galaxy S25 Ultra에서 동작하는 오프라인 우선 개인 AI 비서 앱의 MVP 요구사항을 정의한다.
- 앱은 Gemma 4 E4B-it 기반 로컬 추론을 중심으로 동작하며, 텍스트 · 음성 · 이미지 입력을 받아 개인 비서 기능을 수행한다.
- MVP의 목표는 영화 속 전능한 자비스가 아니라, 개인용 오프라인 AI 비서의 실용적 최소 형태를 구현하는 것이다.

2. 프로젝트 목표

- [1차 목표]
- 오프라인으로 실행 가능한 개인 AI 비서를 스마트폰에서 사용하도록 한다.
- 일정, 메모, 문서, 스크린샷 등 개인 정보 중심 작업을 네트워크 없이 로컬에서 처리하도록 한다.
- 모델 · 메모리 · 도구 구조를 모듈화하여 향후 Windows 및 상위 모델 확장을 가능하게 한다.
- [MVP 목표]
- APK 형태로 Galaxy S25 Ultra에서 구동 가능
- Gemma 4 E4B-it 기반 로컬 추론
- 텍스트 채팅, push-to-talk 음성 입력, 이미지 입력 지원
- 캘린더 조회 및 일정 생성 초안 지원
- 메모/문서 요약 지원
- 로컬 메모리 저장 및 질문 단위 검색 허용 지원

3. 제품 비전

- 오프라인 우선, 개인정보 보호 우선, 사용자 승인 기반 액션, 모델 교체 가능한 구조를 갖춘 비서형 앱을 목표로 한다.
- 모바일 우선으로 시작하되, 데스크톱 확장 가능성과 공통 메모리 구조를 확보한다.

4. 타겟 사용자

- [1차 사용자] 본인 1인 사용자
- [특징] Galaxy S25 Ultra 사용, 로컬 실행 선호, 외부 API 전송 최소화 선호, AI를 실제 보조 도구로 사용하고자 함

5. 핵심 사용 시나리오

- 오늘 일정 요약 요청 → 로컬 캘린더 조회 후 요약 응답
- 메모/문서 정리 요청 → 텍스트 또는 이미지 입력 후 핵심 내용 및 할 일 추출
- 일정 생성 요청 → 초안 작성 후 승인 요청, 승인 시 캘린더 저장
- 음성 버튼 입력 → STT 변환 후 일반 채팅처럼 처리
- 특정 질문에서만 검색 허용 → 로컬 응답 + 웹 기반 보강 응답 구분 표시

6. 제품 범위

- [포함]
 - 텍스트 입력, push-to-talk 음성 입력, 이미지 입력
 - 로컬 LLM 질의응답, 이미지 기반 응답, 메모/문서 요약, 액션 아이템 추출
 - 캘린더 조회, 일정 생성 초안, 승인 후 저장
 - 공유 인텐트 수신, 질문 단위 웹 검색
 - 프로필/대화/작업/지식/감사 로그 저장, export/import
- [제외]
 - 항상 듣기, 완전 자율 실행, 세션 단위 검색 허용, 클라우드 동기화, Windows 앱 구현, 영상 직접 입력

7. 기능 요구사항

- [채팅] 텍스트 질의응답, 최근 대화 일부 반영, 짧고 실용적인 응답
- [음성] push-to-talk, STT 후 텍스트 처리, 실패 시 텍스트 입력 fallback
- [이미지] 스크린샷/문서 사진 중심 질의응답
- [캘린더] 읽기 자동 허용, 쓰기 승인 필요
- [메모/문서] 요약, 핵심 포인트, 해야 할 일 추출
- [검색] 기본 OFF, 질문 단위 ON만 허용
- [공유] 다른 앱에서 전달된 텍스트/이미지를 요약 · 정리

8. 비기능 요구사항

- [오프라인 우선] 기본 기능은 네트워크 없이 동작
- [보안] 외부 전송은 검색 허용 질문에 한함, 민감한 실행은 승인 필요
- [성능] 체감 가능한 응답 속도 유지, 발열 · 메모리 사용량 로그 확인 가능
- [확장성] 모델 교체 가능, Windows 확장을 고려한 공통 메모리 포맷 유지

9. 시스템 정책

- [자동 허용] 텍스트 질의응답, 로컬 메모리 저장, 캘린더 읽기, 요약, 이미지 기반 질문 응답
- [승인 필요] 캘린더 일정 생성, 검색 실행, 외부 공유
- [실행 정책] 읽기 자동, 쓰기 승인, 삭제는 MVP에서 미지원 또는 기본 금지

10. 메모리 설계 요구사항

- Profile Memory: 사용자/설정/보안 선호
- Conversation Memory: 세션별 대화 기록
- Task Memory: 진행 중 작업, 보류 요청
- Knowledge Memory: 사용자 메모, 요약된 문서 정보

- Audit Memory: 모델/도구/승인/검색 사용 이력
- 저장 방식은 JSON + SQLite 혼합
- export/import 및 USB 기반 수동 복사 지원

11. 모델 및 런타임 요구사항

- 모바일 기본 모델은 Gemma 4 E4B - it
- 로컬 실행, 텍스트/이미지 입력 우선, 음성은 STT 후 텍스트 처리
- 모델 구현을 직접 고정하지 않고 공통 인터페이스를 둔다
- 모델 파일은 sideload로 배치하고, 앱은 현재 사용할 모델 정보와 경로를 기록한다

12. UI/UX 요구사항

- 짧고 실용적인 응답, 실행 전 계획/행동 표시, 위험 작업 승인 요청
- 검색 사용 여부 명확 표시, 기본은 오프라인 상태 유지
- 주요 화면: 메인 채팅, 승인 카드, 메모리/데이터 관리, 설정 화면
- 페르소나는 초기에는 간결하고 신뢰형으로 유지

13. 기술적 아키텍처 요구사항

- UI와 모델 런타임 분리, 모델 런타임과 도구 연결 분리, 도구와 정책 분리, 메모리 계층 분리
- 논리 구조: UI Layer / Assistant Core / Model Runtime / Agent Layer / Harness / Memory / Platform Connector

14. 릴리즈 단계 제안

- Phase 1: 텍스트 채팅, 로컬 모델 연결, 기본 메모리 저장
- Phase 2: 음성 입력, 이미지 입력, 메모/문서 요약
- Phase 3: 캘린더 조회, 일정 생성 초안, 승인 플로우
- Phase 4: 질문 단위 검색 ON, export/import, 공유 인텐트

15. 수용 기준

- 텍스트 입력 후 로컬 응답 가능
- 버튼형 음성 입력 후 동일 대화 흐름 처리 가능
- 스크린샷/문서 이미지 업로드 후 의미 있는 응답 제공
- 일정 조회, 일정 생성 초안, 승인 후 저장 가능
- 대화/프로필/작업/로그 저장 가능, export/import 가능
- 검색은 기본 OFF이며 질문 단위로만 ON 가능

16. 리스크 및 대응

- 모바일 성능/발열 → 입력 길이 제한, 분할 처리, 성능 로그 수집
- 멀티모달 품질 편차 → 스크린샷/문서 요약 위주로 범위 제한
- 음성 입력 불안정 → STT fallback 유지
- 권한/실행 실수 → 읽기/쓰기 정책 분리, 승인 UI, 감사 로그 저장
- 메모리 구조 변경 리스크 → 초기부터 레이어 분리 및 포맷 명세화

17. 향후 확장 방향

- Windows 앱 지원, Gemma 4 26B - A4B 연동, 고급 task memory, 로컬 네트워크 동기화
- API 모델 fallback, 고도화된 멀티모달 처리, 더 많은 Android 도구 연동

18. 최종 결정 요약

- Android 우선 / Galaxy S25 Ultra 대상 / Gemma 4 E4B - it 기반 / APK sideload 시작
- 텍스트 + push-to-talk 음성 + 이미지 입력
- 캘린더/메모/문서/공유 중심, 읽기 자동 / 쓰기 승인
- 검색 기본 OFF, 질문 단위 ON만 허용
- 메모리 5계층 분리, export/import + USB 이동, Windows 확장 고려 구조